Workshop 2

Web Scraping
Part 1

Slides courtesy of Skooldio
Modified and used with permission

Skooldio
skills / school / studio

Data Collection

Websites

There are over 1 billion websites on the world wide web today!

Wikipedia
5 million articles in the English Wikipeda

Amazon
400M products sold on amazon.com

TripAdvisor
6.8 million business and properties

Data Collection

Social media

Tons of user-generated content

Facebook
more than 60 million active business Pages

Twitter
500 million tweets per day

Instagram
80 million photos uploaded every day

Data Collection

Open data

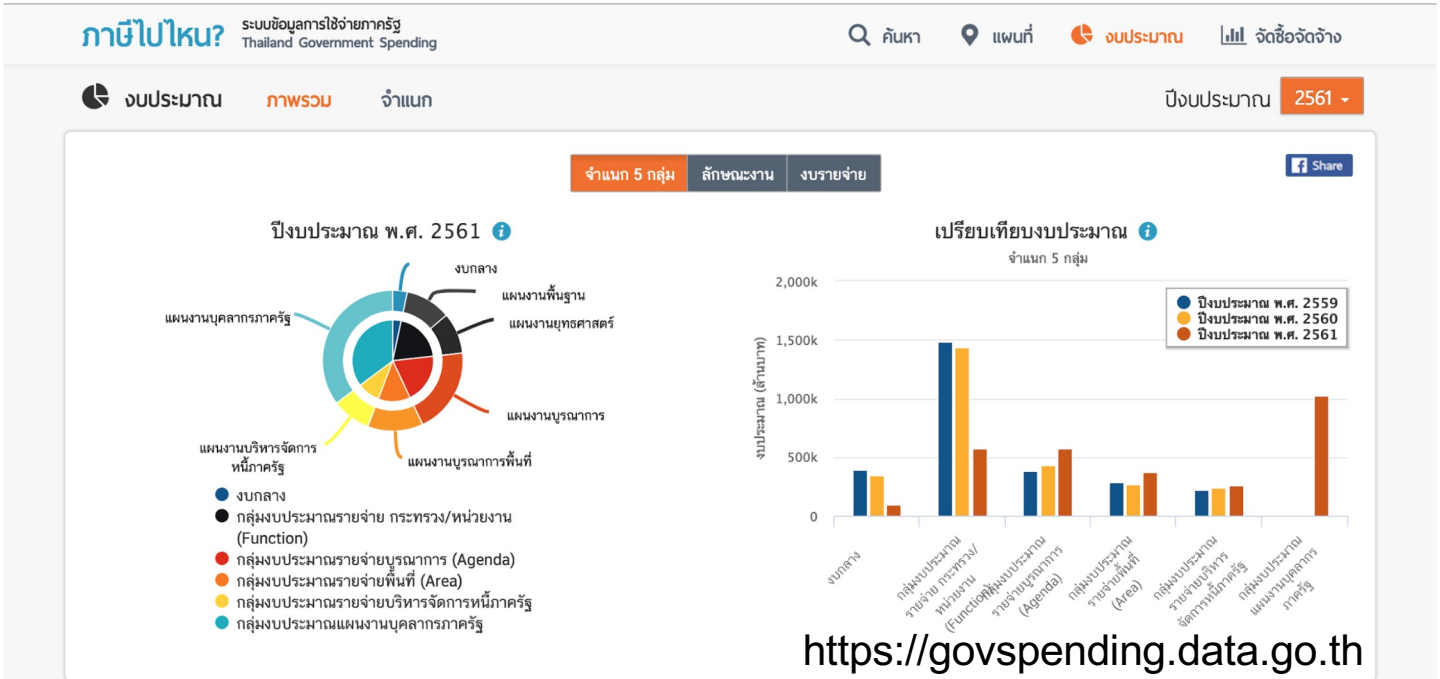

https://govspending.data.go.th

Governmental Open Data https://govspending.data.go.th/

Data Collection

Kaggle

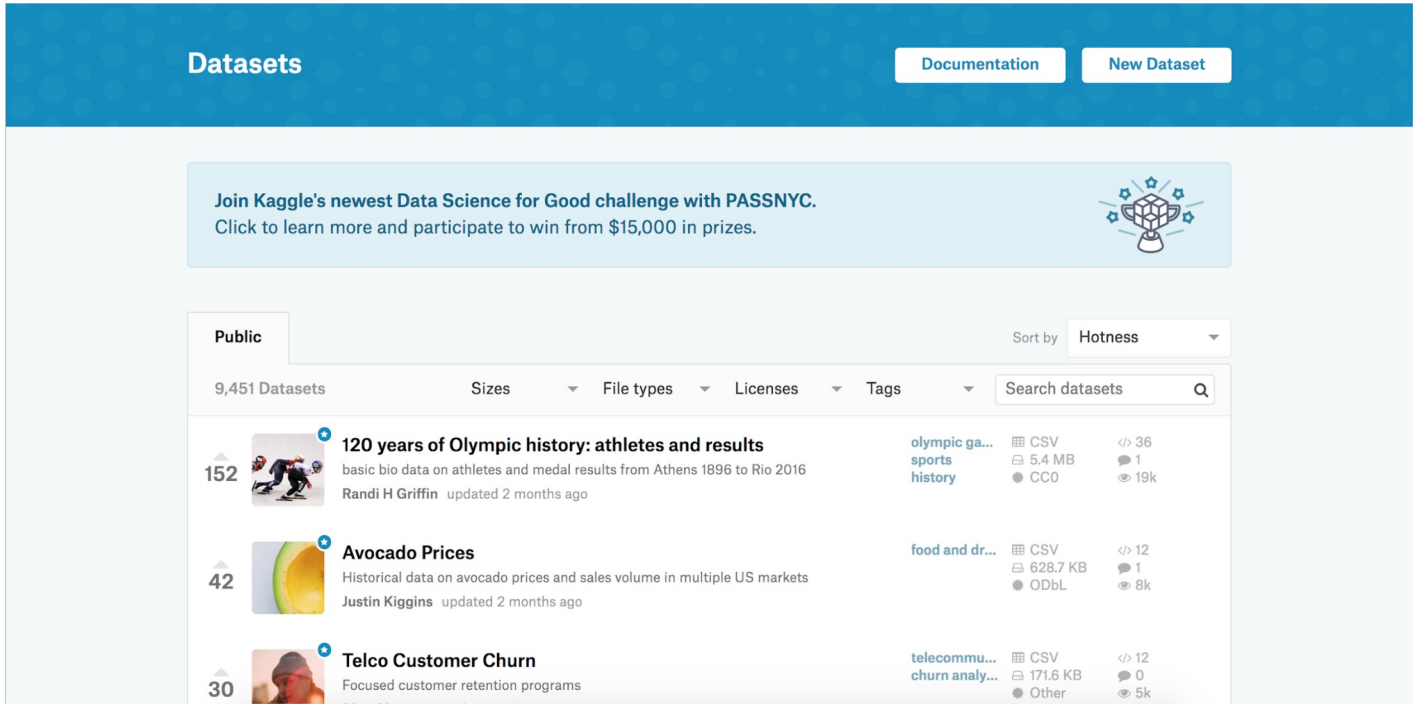

TOPICS

- Web Scraping
- Beautiful soup (next week)

Web Scraping

What is web scraping ?

- A process of extracting information from websites
- It usually refers to an automated program that simulates a person viewing a website
- The process involves downloading a web page, parsing and extracting information from it, and store the target information in a proper format

Use case

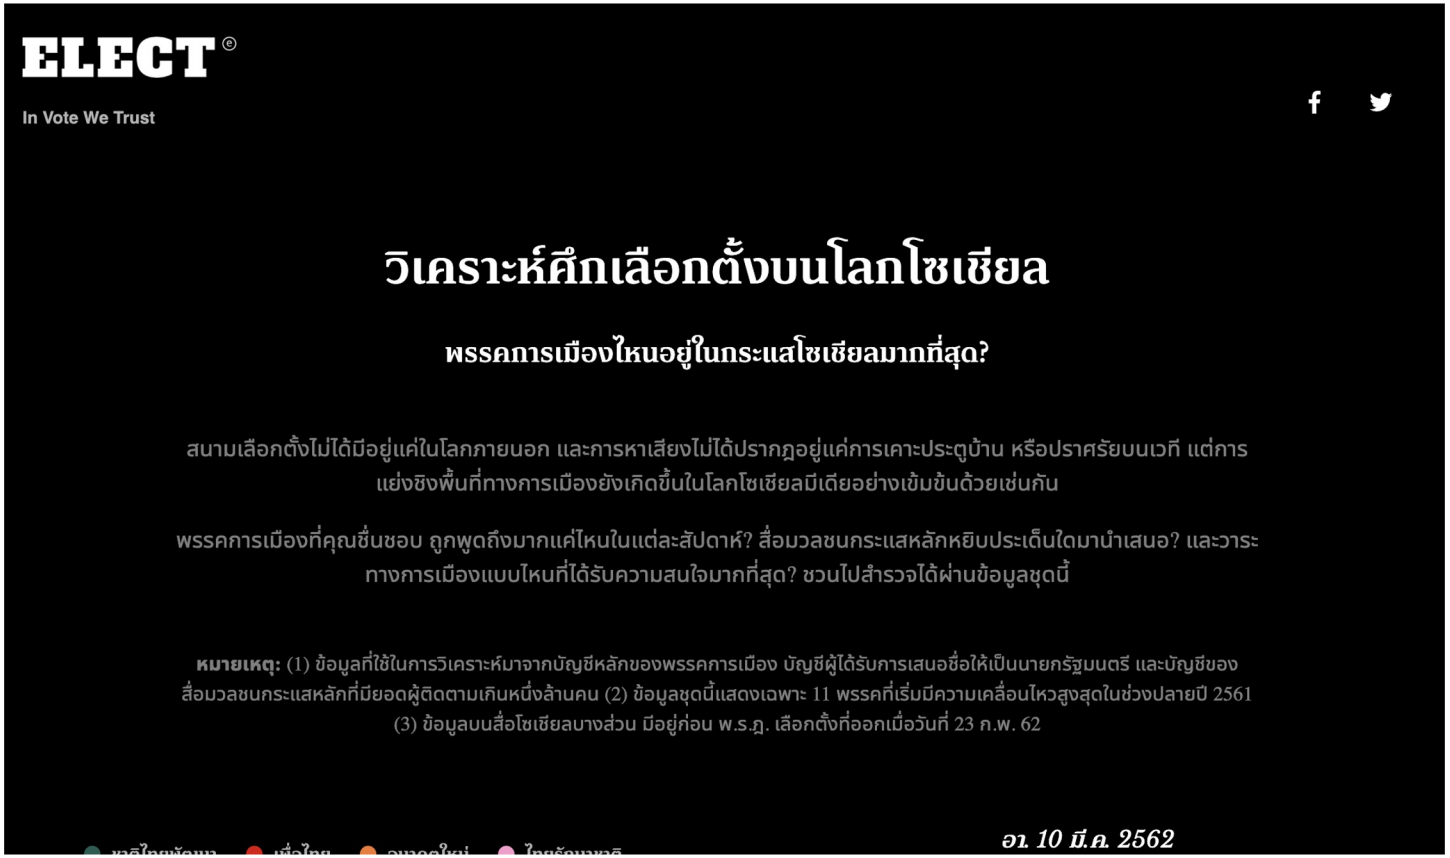

https://elect.in.th/social-listening/

Use case

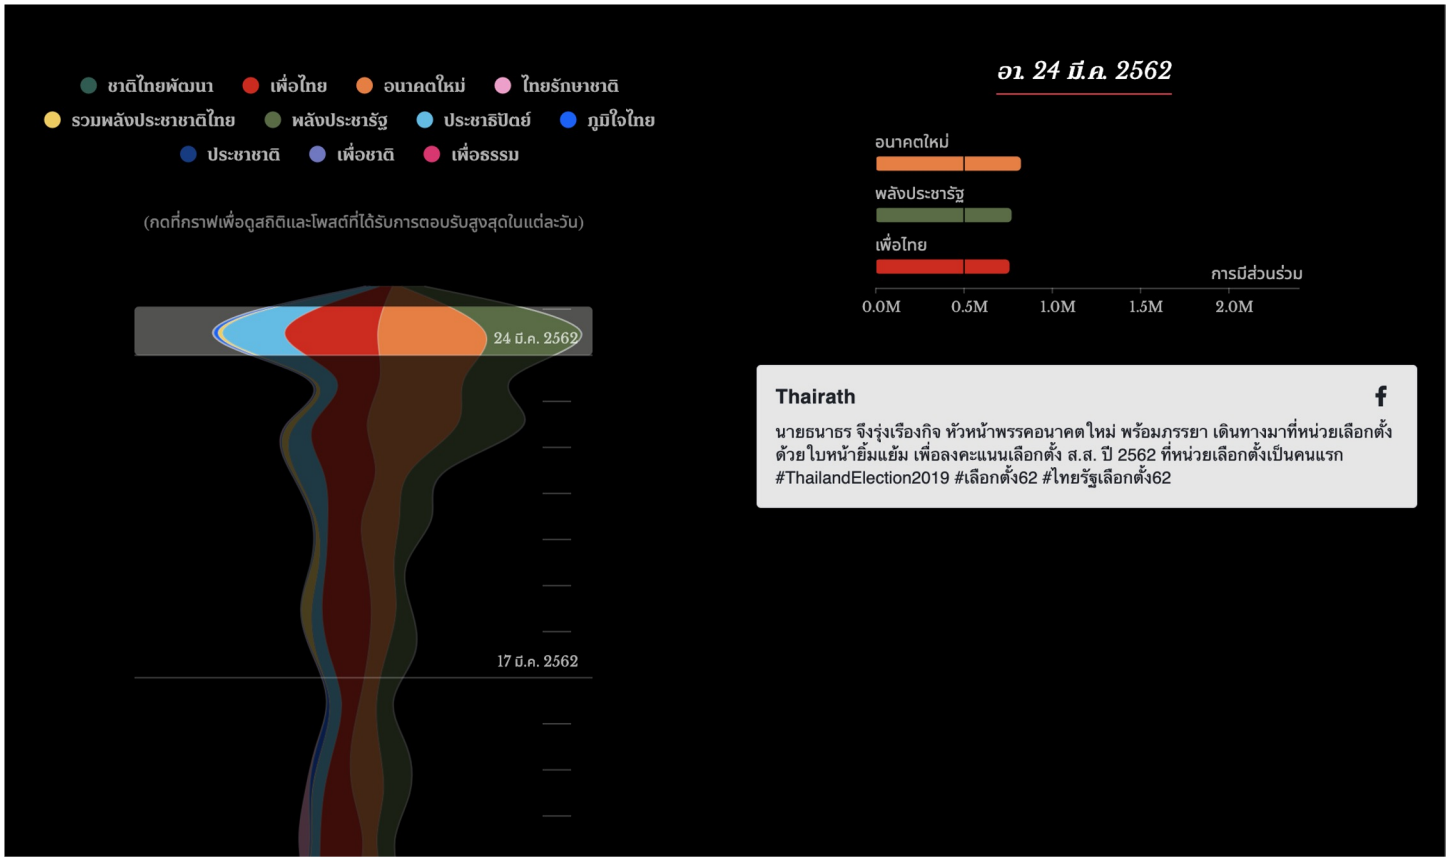
ชาติไทยพัฒนา
เพื่อไทย
อนาคตใหม่
ไทยรักษาชาติ
รวมพลังประชาชาติไทย
พลังประชารัฐ
ประชาธิปัตย์
ภูมิใจไทย
ประชาชาติ
เพื่อชาติ
เพื่อธรรม
(กดที่กราฟเพื่อดูสถิติและโพสต์ที่ได้รับการตอบรับสูงสุดในแต่ละวัน)
24 มี.ค. 2562
17 มี.ค. 2562
อา. 24 มี.ค. 2562
อนาคตใหม่
พลังประชารัฐ
เพื่อไทย
การมีส่วนร่วม
0.0M
0.5M
1.0M
1.5M
2.0M
Thairath
นายธนาธร จึงรุ่งเรืองกิจ หัวหน้าพรรคอนาคตใหม่ พร้อมภรรยา เดินทางมาที่หน่วยเลือกตั้ง ด้วยใบหน้ายิ้มแย้ม เพื่อลงคะแนนเลือกตั้ง ส.ส. ปี 2562 ที่หน่วยเลือกตั้งเป็นคนแรก #ThailandElection2019 #เลือกตั้ง62 #ไทยรัฐเลือกตั้ง62

Ethics

- Always check a website's **Terms and Conditions**
- Publishing the scraped data might violate copyright laws
- Act like a human - make requests at a reasonable rate
- Check the robots.txt file.

robot.txt

- The file tells robots which pages on the site they should not visit
- The file is located in the top-level directory of websites
  - https://en.wikipedia.org/robots.txt
- Robots may simply ignore your instructions!

Scraping Workshop:

Web Scraping

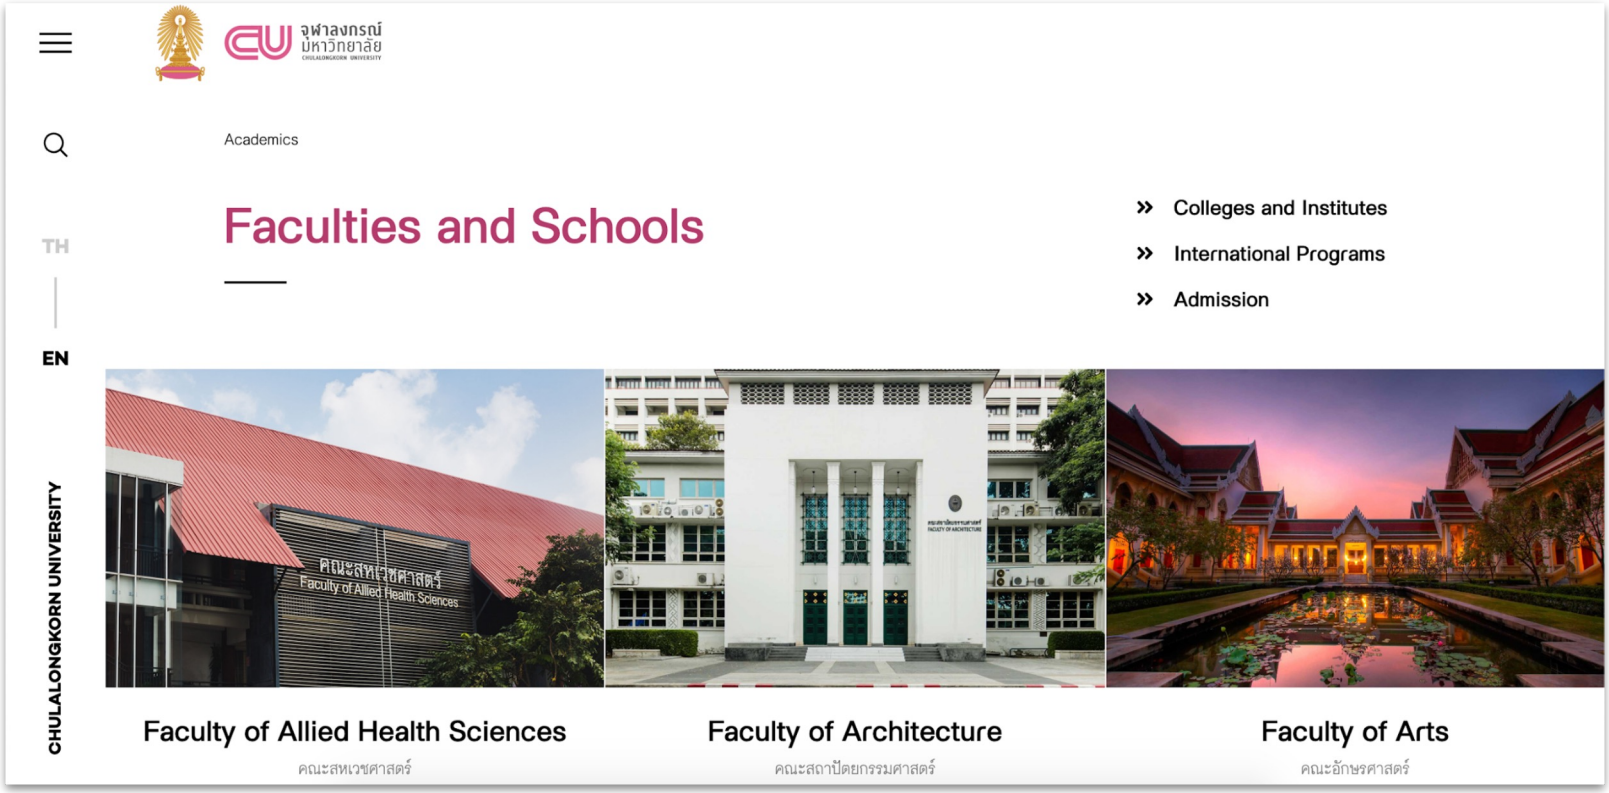

HTML Essentials

HTML (Hypertext Markup Language)

```
<!DOCTYPE html>
<html>
    <head>
        <title>Untitled</title>
    </head>
    </body>
        <p>hello world</p>
    <body>
</html>
```

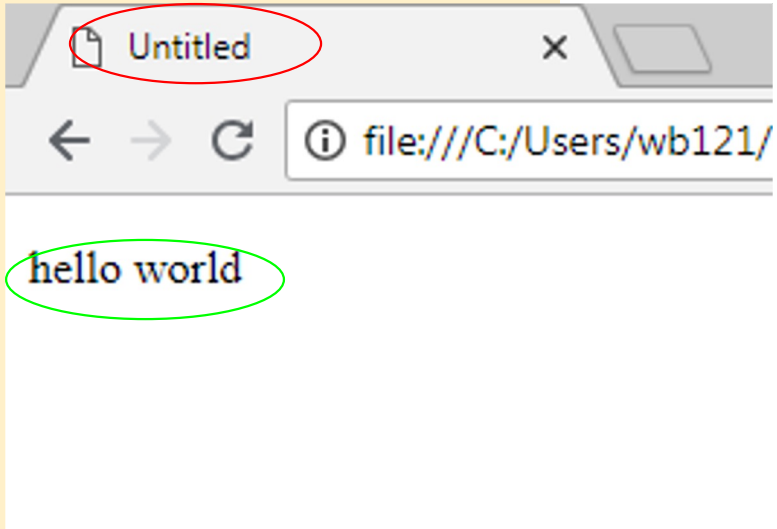

Every statement has opening < > and ending </ >

HTML Tags

 defines a section

```
<! - -  This is a comment  - - >
<div id="group1" class="footnote">
<h1>heading1</h1>
<h6>heading6</h6>
<p style="color:red;">
paragraph with a <a href="google.com">link</a>
and <br>
a <span style="color:darkolivegreen">special
formatted</span> text
</p>
</div>
```

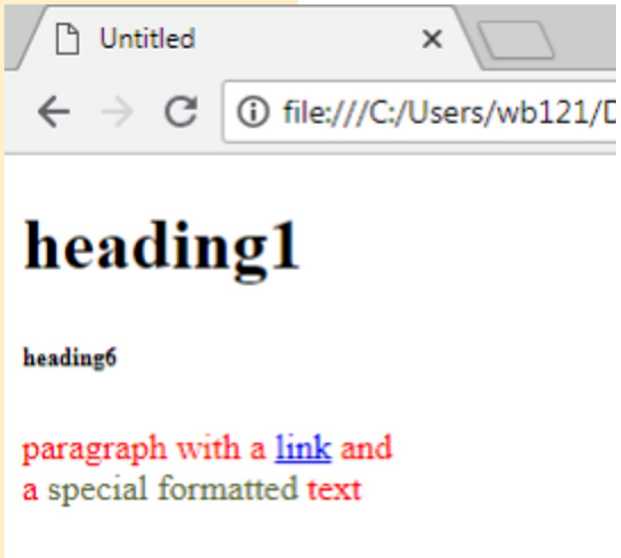

Html ignores “Enter” in the code

 create a new line
Headings <h> and paragraphs <p> automatically enters a new line

HTML Lists

Unordered list

- item
- item
- item

Ordered list

1. first
2. second
3. third

```
<ul>
    <li>item</li>
    <li>item</li>
    <li>item</li>
</ul>

<ol>
    <li>first</li>
    <li>second</li>
    <li>third</li>
</ol>
```

HTML Tables

A	B
A1	B1
A2	B2

<tr> starts a row
<td> starts a cell

```
<table>
    <tr>
        <th>A</th>
        <th>B</th>
    </tr>
    <tr>
        <td>A1</td>
        <td>B1</td>
    </tr>
    <tr>
        <td>A2</td>
        <td>B2</td>
    </tr>
</table>
```

HTML Tables

A	B
A1	B1
A2	B2

<thead> <tbody> <tfoot>

Specifies which part is the header or body.
Can assign special tricks to each part.

```
<table>
    <thead>
        <tr>
            <th>A</th>  <th>B</th>
        </tr>
    </thead>
    <tbody>
        <tr>
            <td>A1</td>  <td>B1</td>
        </tr>
        <tr>
            <td>A2</td>  <td>B2</td>
        </tr>
    </tbody>
</table>
```

HTML Tables

A	B1
	B2

```
<table>
        <tr>
                <td rowspan=”2”>A</td>
                <td>B1</td>
        </tr>
        <tr>
                <td>B2</td>
        </tr>
</table>
```

HTML Attributes

- **id** provides a document-wide unique identifier for an element

- **class** specifics one or more classes for an element

```
<div class="content"></div>
<div class="content highlight"></div>
```

DOM Tree (Document Object Model)

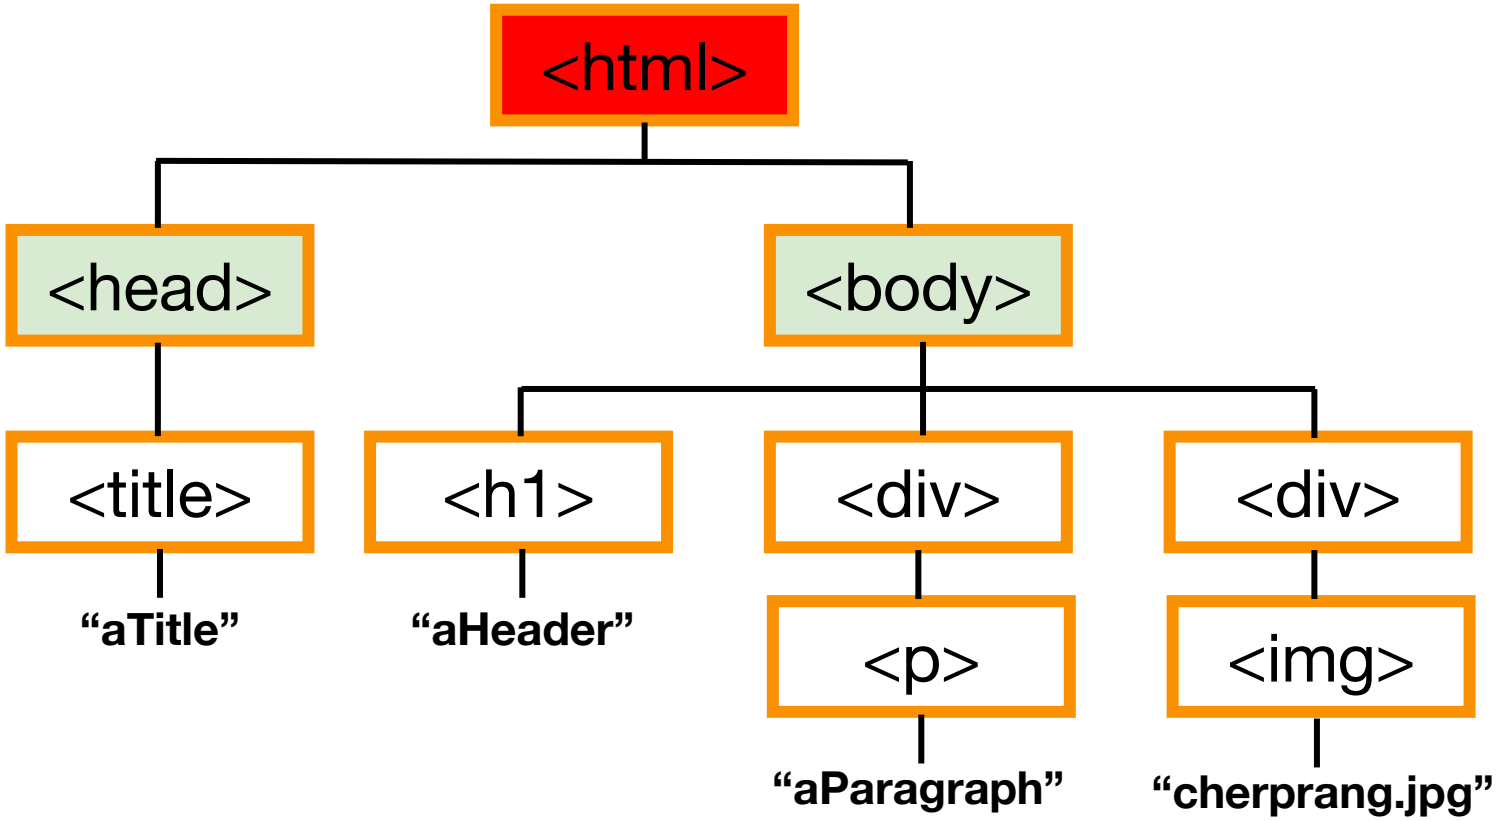


```
1  <!DOCTYPE html>
2  <html>
3  <head>
4  <title>aTitle</title>
5  </head>
6  <body>
7  <h1>aHeader</h1>
8  <div id="group1" class=
9  <p>aParagraph</p>
10 </div>
11 <div id="group2">
12 <img src="cherprang.jpg
13 </div>
14 </body>
15 </html>
```

Lab 0 : Inspect a web page

- ทดลอง inspect เว็บไซต์ โดยเข้าไปที่
- https://comprogchula.github.io/

- เปิด Developer Tools ใน web browser (แนะนำให้ใช้ Chrome)

- Google Chrome:
  View -> Developer -> Developer Tools

Lab 1 : Crawl a web page

- Part I: แสดงชื่อคณะทั้งหมดของจุฬา บรรทัดละชื่อ
- Part II: โหลดรูปคณะต่างๆ
- Part III: หาเบอร์โทร

Useful things to know

str.find

Find location of text

```
txt = “This is a pen. That is a pencil.”
ind = “0123456789012345678901234567890 1”

x = txt.find(“pen”)
print(x)
>10

x = txt.find(“pen”,11)
print(x)
>25

x = txt.find(“pens”)
print(x)
>-1
```

str.replace

Find location of text

```
txt = “This is a pen. That is a pencil.”

x = txt.replace(“pen”,“ben”)
print(x)
>This is a ben. That is a bencil.

x = txt.replace(“pen”,”ben”,1)
print(x)
>This is a ben. That is a pencil.
```

open

Prepares a file for reading/writing

```
fin = open( “asdf.txt”, “r”)  # r means open for reading
line = fin.readline() # read a line
for line in fin: # read until end of file
  ...
fin.close()
```

open

Prepares a file for reading/writing

```
fout = open( “asdf.txt”, “w”)  # open for writing
fout.write(“something”)
fout.close()
```

When writing binary files,
add “b”
เช่น “rb” “wb”

urllib

Read a url

```
import urllib
import urllib.request as urq
url = 'https://www.chula.ac.th/en/academics/faculties-and-schools'
html = str(urq.urlopen(url).read().decode('utf-8'))
```

เข้าเวบไซต์

อ่าน html

แปลงภาษาไทย

read and write images

ขั้นตอนการอ่านและบันทึกไฟล์ภาพ

1. อ่านภาพจากลิงค์

- d = url.urlopen([ลิงค์ของภาพ])

2. สร้างไฟล์พร้อมระบุตำแหน่งที่จะเก็บไฟล์ภาพ

- l = open([ระบุตำแหน่งที่จะเก็บภาพ]) เป็นแค่ตัวอย่าง โค้ดจริงๆเขียนแบบนี้จะผิด ต้องมีอะไรเพิ่มสำหรับการเปิดไฟล์อ่าน/เขียน

3. บันทึกข้อมูลภาพไปยังตำแหน่งที่เก็บไฟล์ตามที่ระบุไว้ในข้อ (2.)

- l.write(d.read())

4. ปิดไฟล์

- l.close()

Next week : beautifulsoup

Web Scraping with Python

Setup prerequisite

1. Anaconda (Python 3)

1. Jupyter Notebook or Jupyter Lab

1. BeautifulSoup Library
   -> Run from bs4 import BeautifulSoup

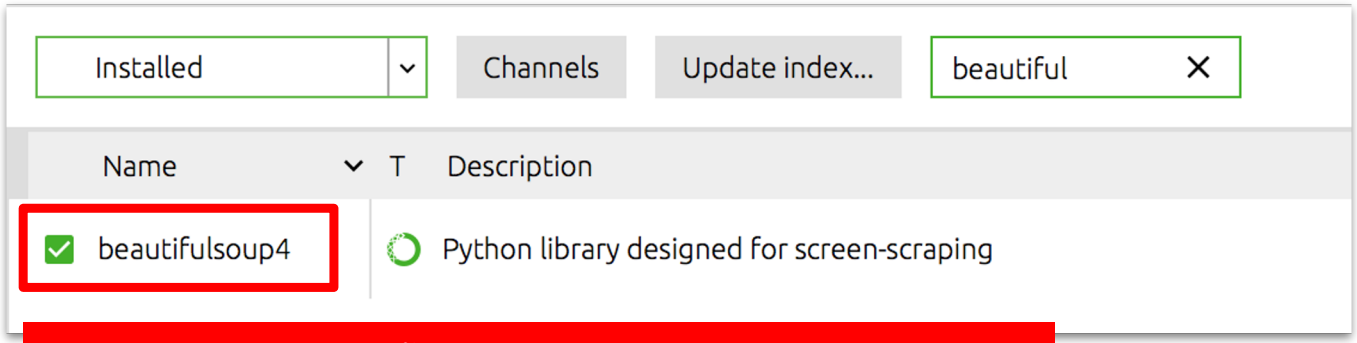

ตรวจสอบว่าได้ติดตั้ง **BeautifulSoup4** เรียบร้อยแล้ว

BeautifulSoup Primer

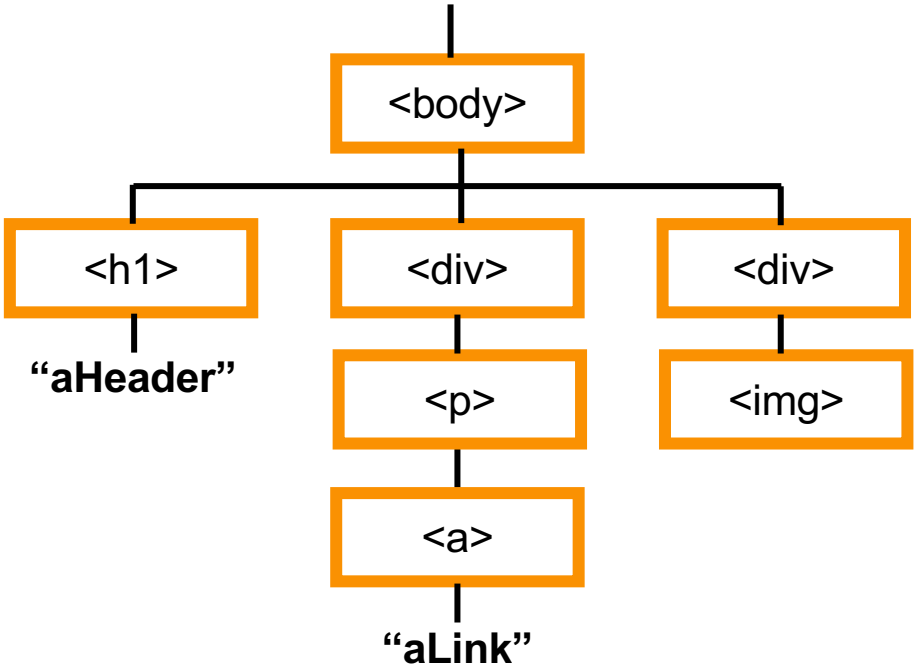


```
<body>
        <h1>aHeader</h1>
        <div class="section1">
                <p>
                        <a href="#">aLink</a>
                </p>
        </div>
        <div class="section2">
                <img src="img.jpg/>
        </div>
</body>
```

Workshop 2.1 : BeautifulSoup

01-basic_beautifulsoup.ipynb

https://colab.research.google.com/drive/1jyS7ZBdARc9OrK2rYMv2Au_SxwhM8DRC

BeautifulSoup Primer : Find the target element

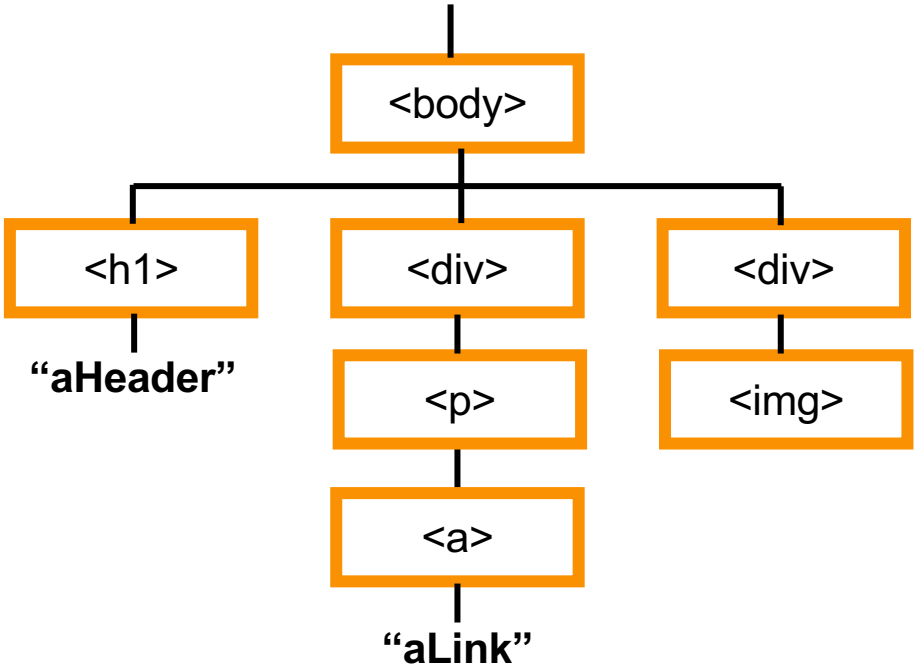


```
s = BeautifulSoup(html,'html.parser')

s.body
```

BeautifulSoup Primer : Find the target element

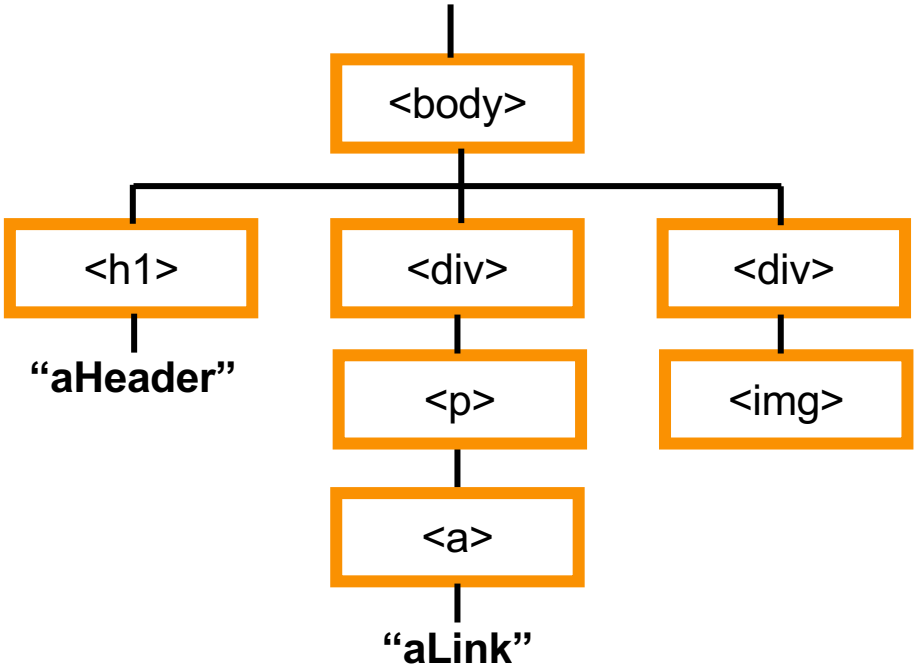


```
s.h1
```

or

```
s.find('h1')
```

BeautifulSoup Primer : Find the target element

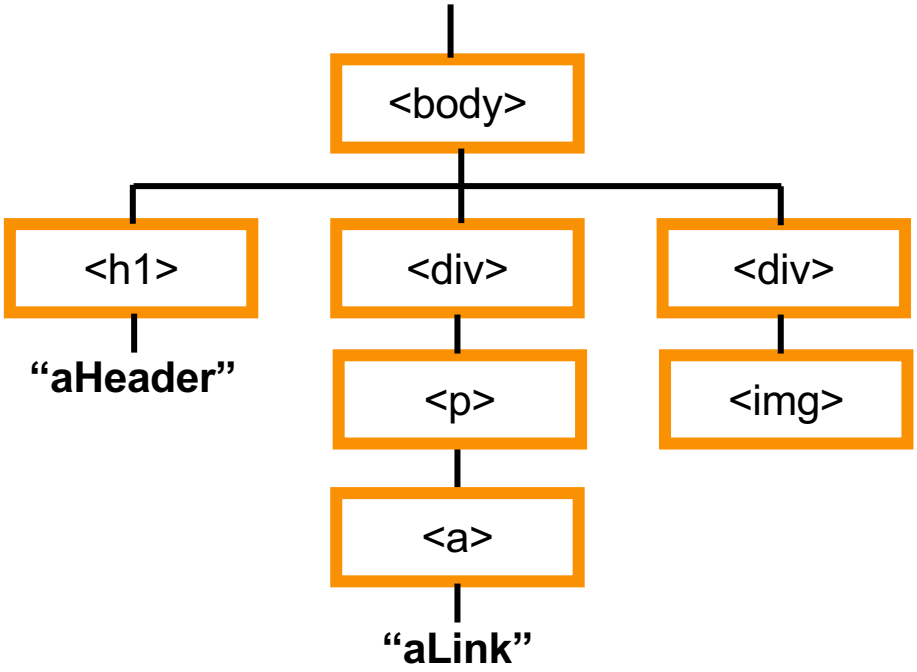


```
s.div
```

or

```
s.find('div')
```

BeautifulSoup Primer : Find the target element

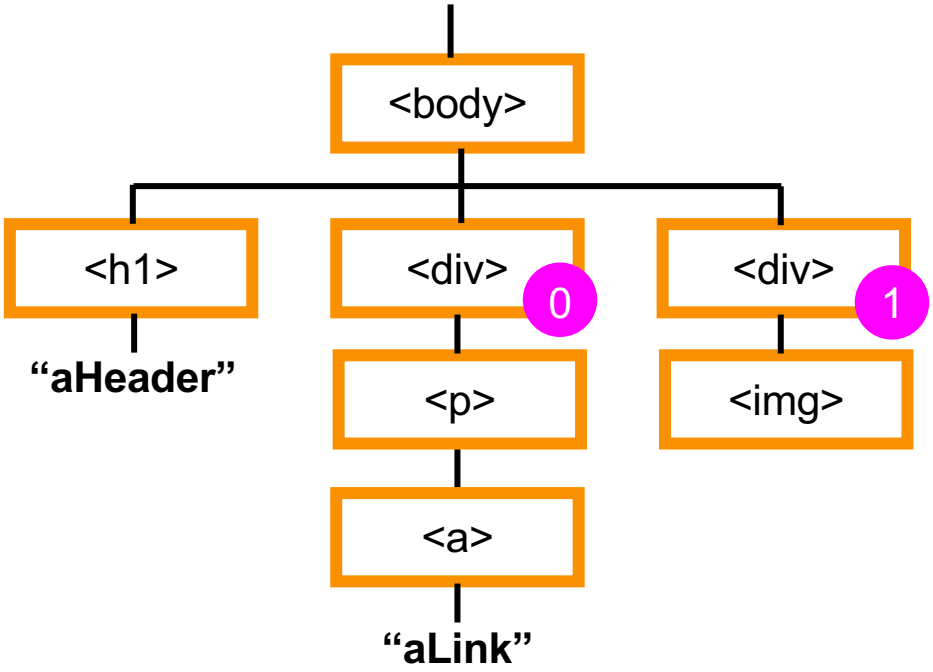


```
s.('div')
```

or

```
s.find_all('div')
```

BeautifulSoup Primer : Find the target element

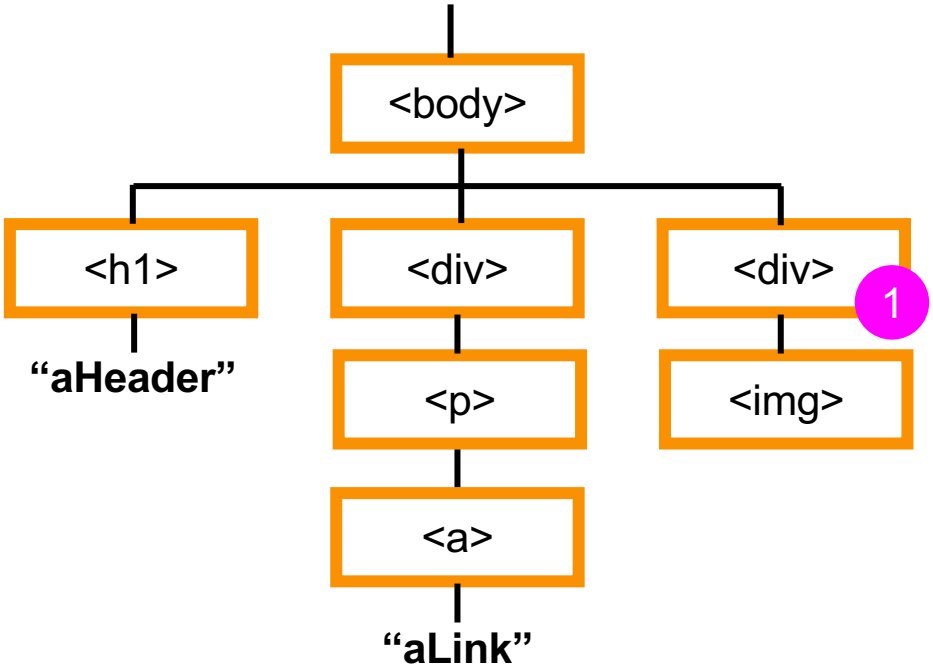


```
s.('div')[1]
```

or

```
s.find_all('div')[1]
```

BeautifulSoup Primer : Find the target element

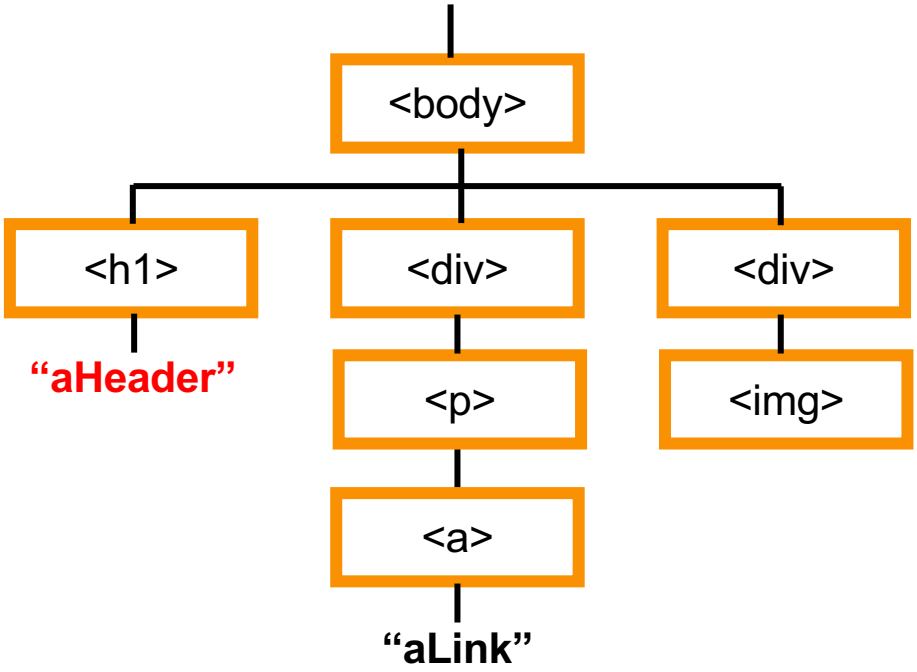


```
s.find(text='aHeader')
```

BeautifulSoup Primer : Find the target element

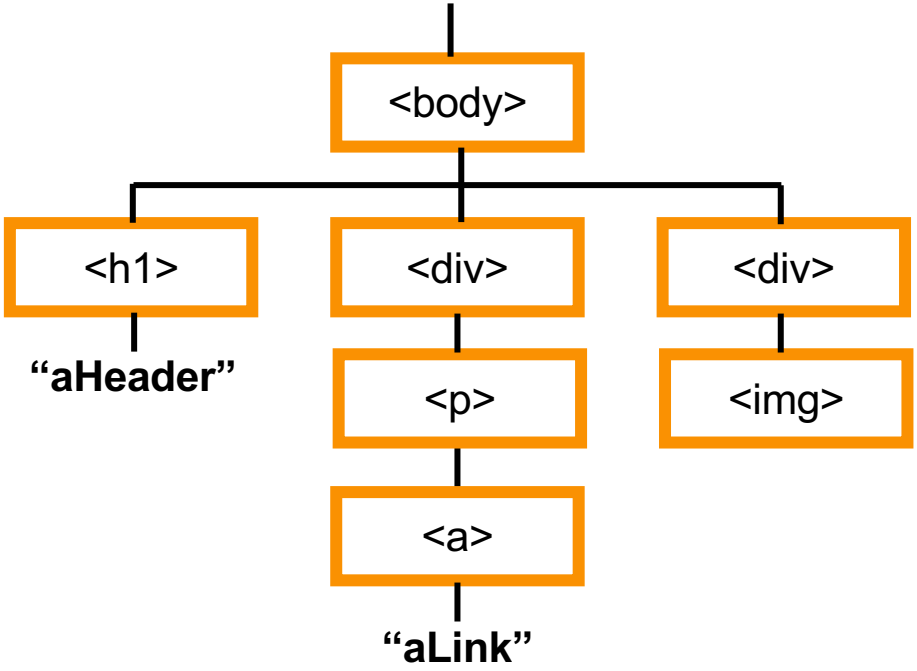


```
s.find('h1' , string='aHeader')
```

BeautifulSoup Primer : Find the target element

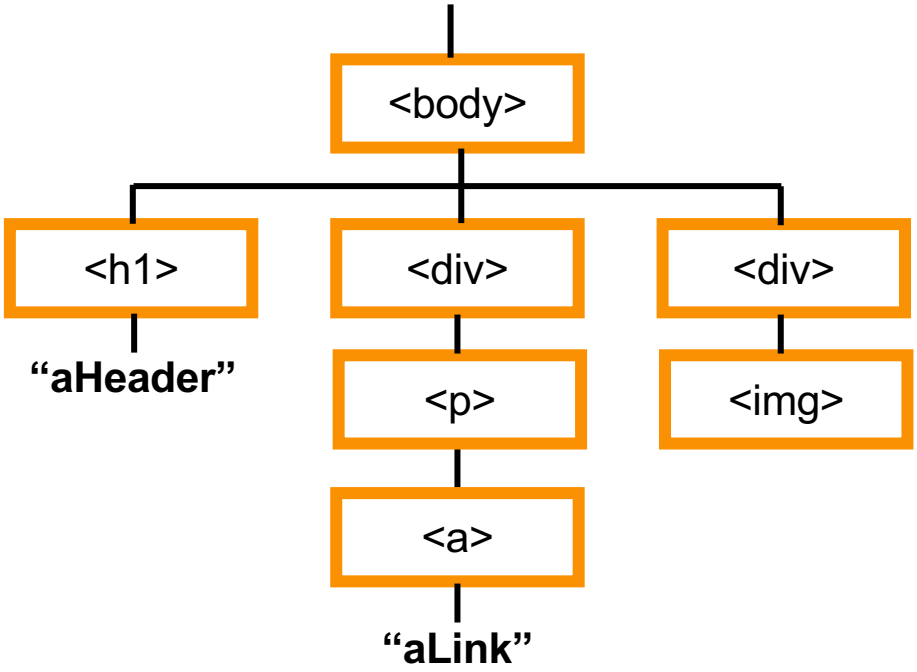


```
s.find( attrs={ 'class' : 'section1' } )
```

or

```
s.find(class='section1')
```

BeautifulSoup Primer : Traverse the DOM tree

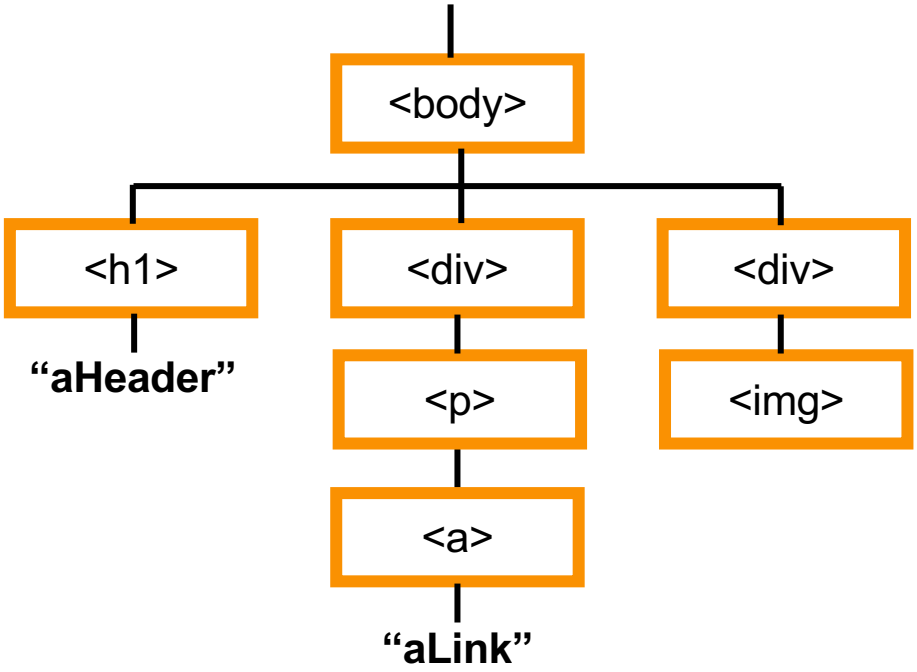

s.div.parent

BeautifulSoup Primer : Traverse the DOM tree

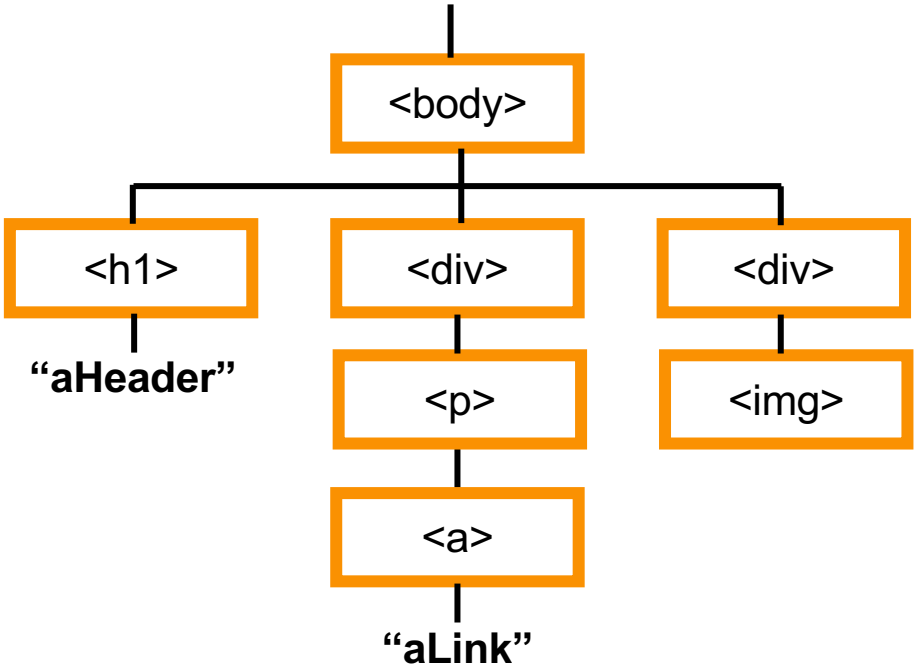


```
s.div.previous_sibling
```

BeautifulSoup Primer : Traverse the DOM tree

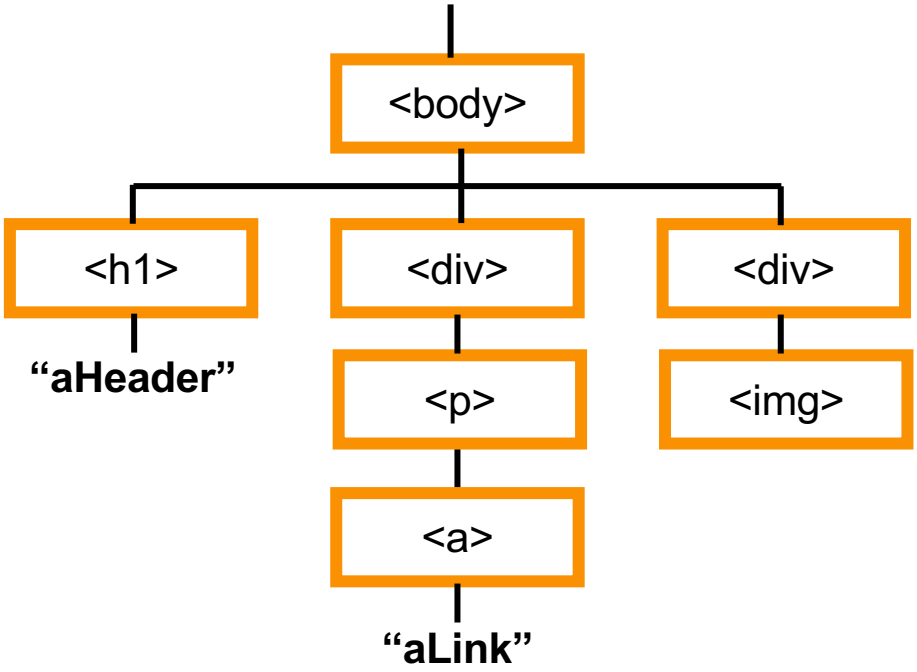


```
s.div.next_sibling
```

BeautifulSoup Primer : Traverse the DOM tree

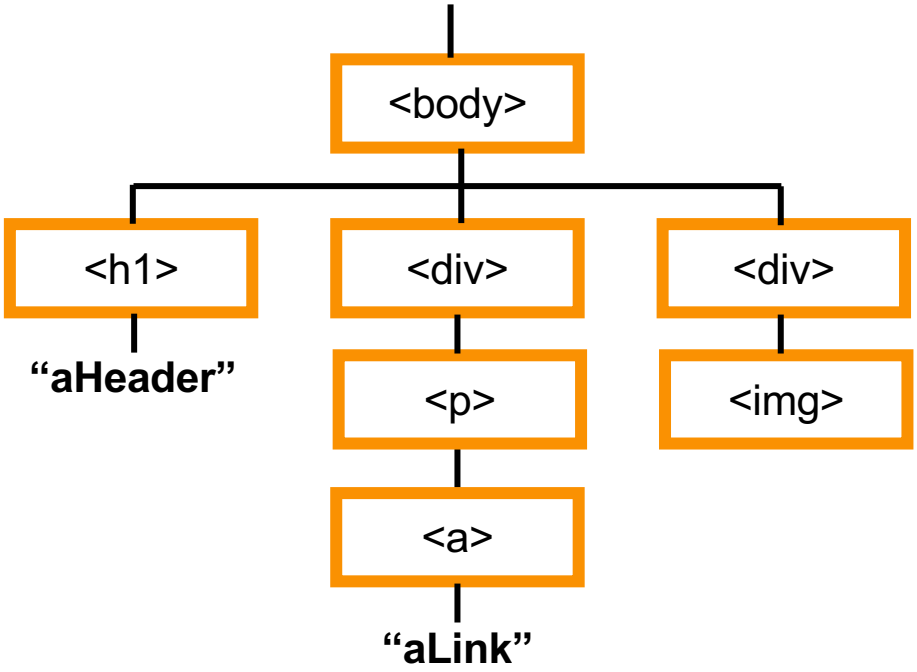


```
s.div.next_element
```

BeautifulSoup Primer : Traverse the DOM tree

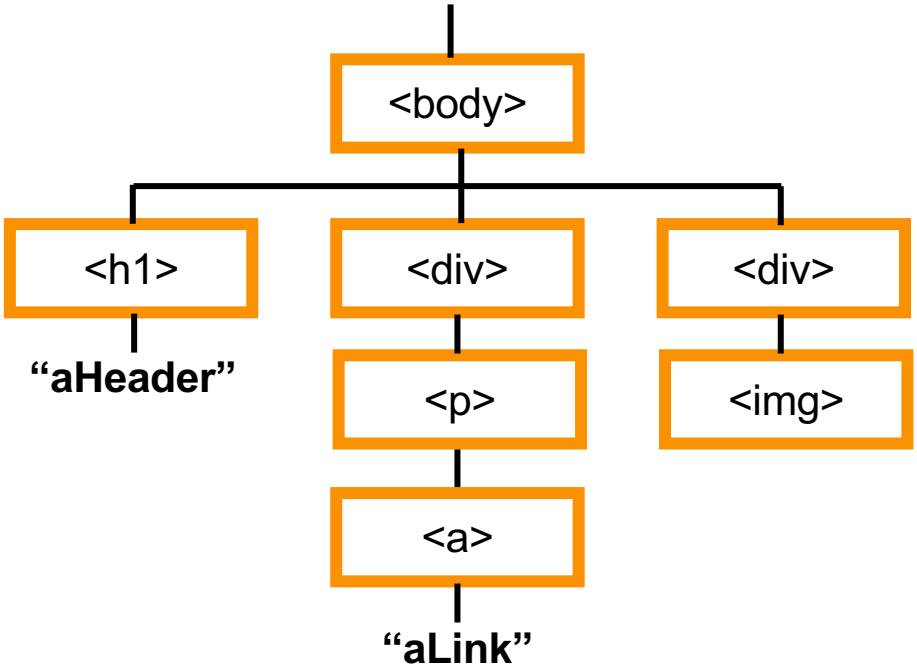

s.div.parent

Warning : for white spaces !!!

จะเกิด ช่องว่าง **(space)** และ ขึ้นบรรทัดใหม่ **(new lines)** ระหว่าง **tag**

```
<body>
        <h1>aHeader</h1>
        <div class="section1">
                <p>
                        <a href="#">aLink</a>
                </p>
        </div>
        <div class="section2">
                <img src="img.jpg/>
        </div>
</body>
```

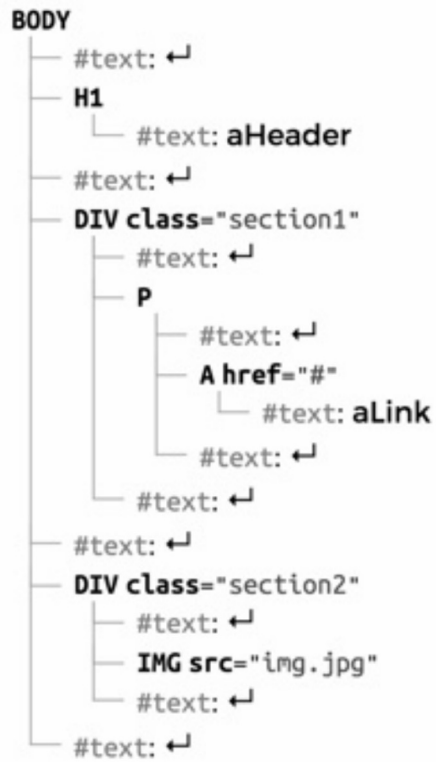

BeautifulSoup Primer : Traverse the DOM tree

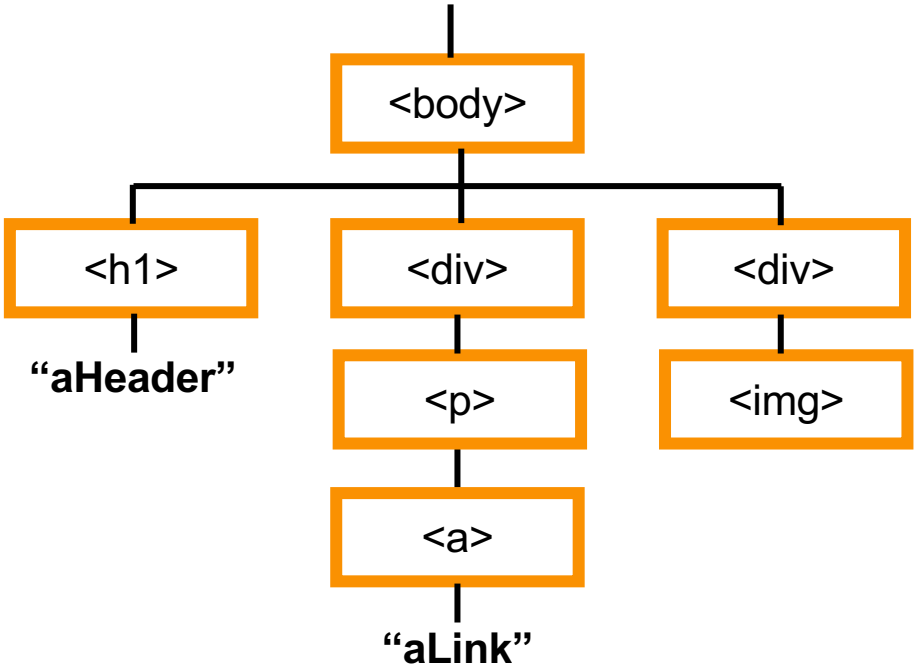


```
s.a.find_next()
```

BeautifulSoup Primer : Traverse the DOM tree

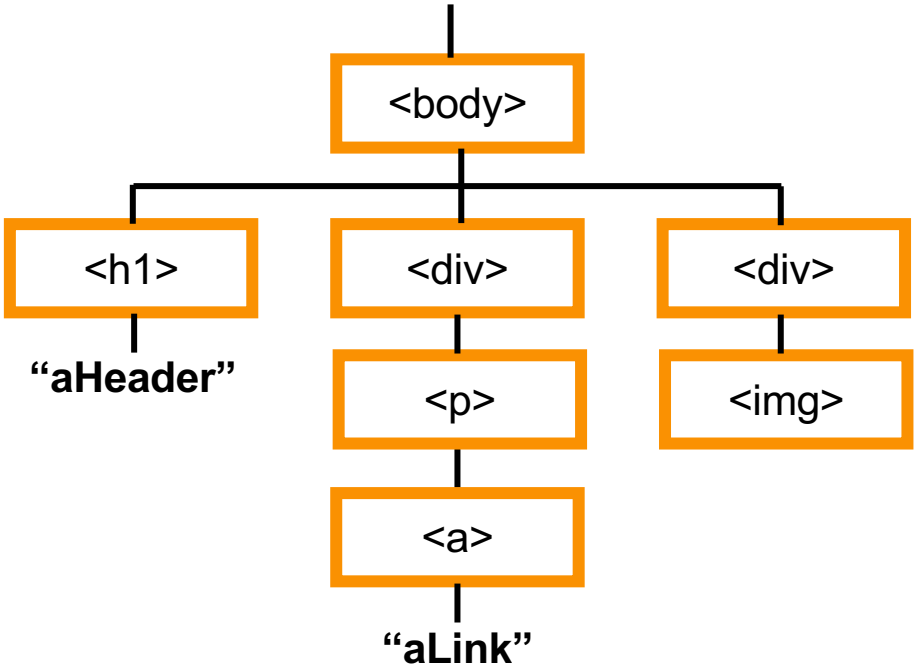


```
s.a.find_next('img')
```

BeautifulSoup Primer : Traverse the DOM tree

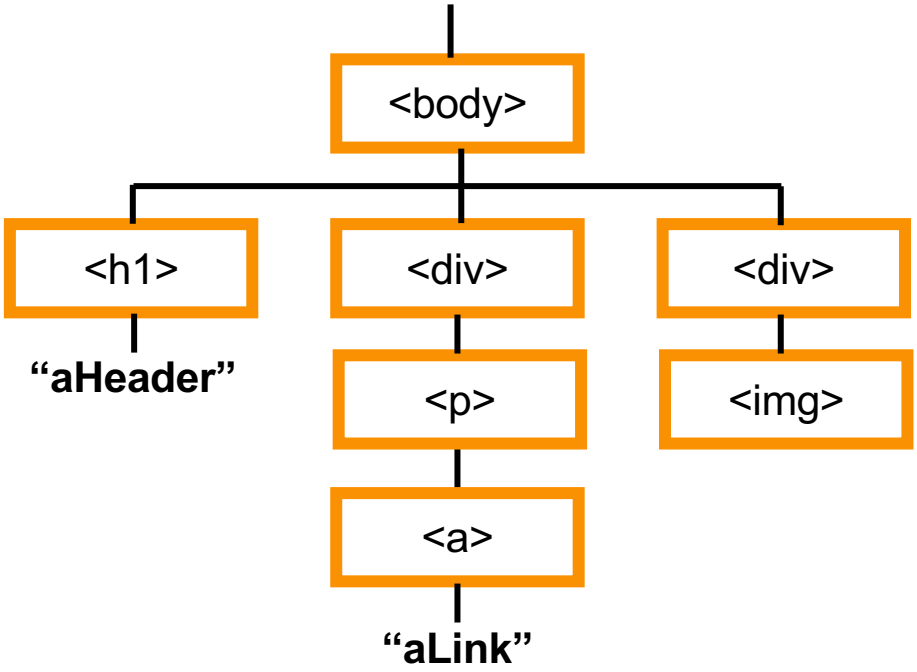


```
s.find('div', class_='section2') \
    .find_previous_sibling('h1')
```

Workshop 2.2 : Data Scraping

02-web_scraping.ipynb

- ดึงข้อมูลรายชื่อบริษัทในเครือปัจจุบันในสังกัด GDH
- ดึงข้อมูลรายชื่อผู้กำกับภาพยนตร์ในสังกัด GDH
- ดึงข้อมูลรายชื่อนักแสดงในสังกัดนาดาวบางกอก
- ดึงข้อมูลรายชื่อภาพยนตร์ในเครือ GDH พร้อมทั้ง วันเปิดตัว , รายได้ และ ผู้กำกับ